

# PPG 센서를 이용한 음주 상태 추정 방법 연구

## A Study on the Estimation Method of Drinking Condition using PPG Sensor

○최혜정<sup>1</sup>, 방유석<sup>1</sup>, 강태구<sup>1\*</sup>

<sup>1)</sup> 상명대학교 휴먼지능로봇공학과 (TEL: 041-550-5405, E-mail:tkkang@smu.ac.kr)

**Abstract** This paper proposed a model for estimating the user's alcohol consumption by learning the sence signal measured through a PPG sensor. The proposed method pretreated the PPG signal according to the amount of alcohol consumed and extracted it once a cycle, and the amount of alcohol consumed was estimated by learning it through the LSTM-CNN method. The proposed method shows excellent accuracy through experiments and is judged to have high utilization.

**Keywords** PPGSensor, Breathalyzer test

### 1. 서론

현재 우리나라 음주운전단속의 경우 차도를 통제 하여 음주측정기를 가지고 운전자의 음주 여부를 확인하는 방법을 사용한다. 이는 많은 인력이 투입 될 뿐만 아니라 교통을 통제하기 때문에 교통 혼잡 등 운전자들의 불편을 야기할 수 있다. 따라서, 이러한 연구를 통하여 사용자 스스로 음주량을 알수 있는 방법은 제안하고자 한다.

### 2. PPG 센서를 이용한 음주 상태 추정

#### 2.1 PPG 센서를 이용한 음주 데이터 수집

섭취하는 알코올의 종류는 양주이고 도수는 약 40%였으며, 피실험자 1인당 총 섭취량은 소주잔 기준 12잔으로 하였다. 이는 대학생의 38.4%가 1회 평균 음주량이 10잔[8], 그 중 타인에 비해 주량이 센 실제 주량이 14.9잔임[2]을 참고하여 섭취 잔 수를 정하였고, 음주 시 신체의 변화를 확실하게 알 수 있도록 도수가 높은 알코올을 선택하였다. 총 섭취 시간은 약 150분(약 10분마다 한잔 섭취, 6잔 섭취 전 쉬는 시간 20분)으로 정하였다.

#### 2.2 딥러닝을 이용한 음주 상태 추정

본 연구에서는 PPG 신호에 대하여 딥러닝을 이용한 음주 여부를 판단하는 기법을 제안한다. 제안하는 기법은 PPG에서 측정된 데이터를 펄스 단위

로 구분하고, 이를 딥러닝 알고리즘으로 음주 여부를 판단하는 구조로 한다.

LSTM-CNN은 LSTM과 CNN을 합친 구조이다. 이 조합은 각 구조의 단점을 서로 보완할 수 있으며 end-to-end로 각 layer마다 학습의 성능을 향상시킬 수 있다는 장점을 가진다. 시계열 데이터의 장기종속성에 강한 LSTM과 합성곱을 이용해 정확도를 높인 CNN을 합쳐 시계열 데이터의 정확성을 높일 수 있다. LSTM-CNN 조합의 장점을 이용하여 3D CNN-LSTM 구조로 비디오 품질을 평가한다거나[3], 1D Convolution을 이용하여 텍스트 데이터를 학습시켜 연구한 미세먼지 예측[4], 또는 영화리뷰에 대한 감성을 분석하는[5]등 다양한 데이터로 평가, 예측을 하는 연구들이 진행되나 있다.




그림 1. LSTM-CNN 구조[5]

#### 2.3 음주량에 따른 PPG 데이터

모든 피실험자는 동일한 장소와 동일한 환경에서 약 40도의 알코올을 소주잔 기준으로 1~5잔은 10분 간격, 6잔째 섭취 전 20분의 휴식, 6~12잔은 5분 간

격으로 섭취를 하게 하였으며, 12잔째를 제외하고는 모두 섭취 후 약 20초를 기다린 후 데이터 측정을 진행하였다. 그림 2는 음주 실험 절차를 나타낸다.




그림 2. 음주 실험 절차

그림 3은 음주량에 따른 PPG신호의 변화를 나타낸다. 그림 3을 분석해보면 음주 실험의 절차를 조금 알 수 있다. 1~5잔째까지는 PPG 데이터의 최댓값이 증가하고 주기가 짧아져 심박 수가 점차적으로 증가하는 것을 볼 수 있지만, 20분의 휴식을 취한 후 6잔째 섭취했을 때 PPG 데이터는 바로 직전의 단계인 5잔째의 PPG 데이터 보다 최댓값이 줄었다.




그림 3. 음주량에 따른 PPG데이터

#### 2.4 PPG 데이터 전처리

생체신호는 사용자의 상태에 대한 정보를 가장 잘 제공해준다. 이러한 신호를 분석하기에 가장 중요한 것은 신호의 주파수 영역이다. 6가지 생체센서의 주파수는 모두 다른데, 그 중 PPG 신호의 경우에는 0.1hz ~ 10hz에 해당하고, 이것은 생체 신호 중 가장 낮은 주파수 대역이다. 또한 PPG 신호의 특성 중 하나는 피크 값을 기준으로 주기적으로 같은 파형을 가진다는 것이다. 또한, 피크 값의 주기가 심장박동주기와 같다. 일반적으로 심박은 1분에 60~100정도가 정상인데, 심박 수는 사람마다 다르므로 학습을 위해서는 일정한 길이의 데이터가 필요하기 때문에 피크 값을 기준으로 한 주기씩 나누어

처리하였다. 따라서 효율적인 학습을 위해 PPG 값의 피크를 기준으로 한 주기씩 나누어준다. 그림 4는 그림 3의 PPG데이터를 한주기로 나누어 그래프에 나타낸 모습이다.

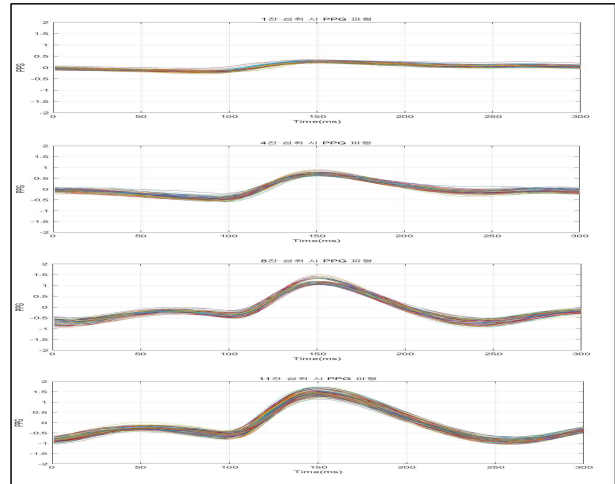


그림 4. 1잔, 4잔, 8잔, 11잔 섭취 시 PPG 신호 전처리 결과

### 3. 실험 결과

본 장에서는 제안된 방법을 이용하여 음주량 추정 실험의 정확도 실험을 수행하였다. Input 모델은 시퀀스의 길이 200, 채널 수 1, output은 클래스 4(1잔:1, 4잔:2, 8잔:3, 11잔:4)로 정의하였다. 시퀀스의 길이는 전처리를 한 데이터의 길이이며, 채널의 수는 PPG 신호를 뜻하고, 클래스는 1잔, 4잔, 8잔, 11잔 총 4 클래스를 나타낸다. 또한, 학습 파라미터는 LSTM에서 filter=128을, CNN에서는 filter=256, kernel\_size=3, padding='valid', activation='relu', strides=1로 설정하였고 Maxpooling을 진행하였다. LSTM-CNN은 CNN layer에서는 filter=256, kernel\_size=3, padding='valid', activation='relu', strides=1로 진행하였으며, LSTM layer에서는 filter=128을 사용하였다. optimizer로는 Adam을 선택하였으며, epochs=100, batch\_size=64로 세 알고리즘에서 모두 동일하게 사용하였다. 이에 더해, 사람마다 PPG데이터가 매우 상이하기 때문에 개개인별로 예측 실험을 진행하였다. 그림 4는 LSTM, CNN, LSTM-CNN 각각의 학습 과정을 시각화 한 모습이다.

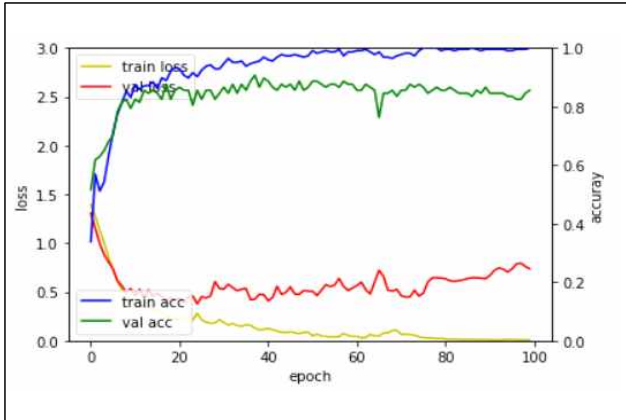


그림 4. LSTM-CNN 학습 과정 시각화

표 1은 총 14명에 대한 섭취량을 예측한 결과를 보여준다. 학습의 속도는 CNN이 가장 빨랐고 LSTM이 가장 느렸다. 정확도는 CNN이 가장 좋지 않은 결과를 보였으며, LSTM-CNN이 대부분의 사람에 대해 정확도가 가장 높았다. LSTM은 LSTM-CNN만큼 좋은 정확도를 보이지는 못했지만, CNN보다는 확연히 좋았으며, 몇몇 사람들의 결과에서는 LSTM이 더 뛰어난 결과를 보이기도 했다. 결론적으로는 LSTM-CNN이 가장 좋은 정확도를 보여주었다.

표 1. 14명에 음주량 예측 정확도

사람 \ 알고리즘	LSTM	CNN	LSTM-CNN
1	0.8454	0.8247	0.9072
2	0.7320	0.6495	0.7629
3	0.9175	0.6392	0.8969
4	0.8866	0.7320	0.9278
5	0.5876	0.6289	0.7113
6	0.7423	0.7113	0.8763
7	0.6289	0.6186	0.6701
8	0.8247	0.4845	0.8557
9	0.6082	0.4536	0.6082
10	0.9794	0.9278	0.9381
11	0.6289	0.5567	0.6082
12	0.7010	0.6804	0.7835
13	0.5979	0.3196	0.6701
14	0.5773	0.6082	0.6392

#### 4. 결론

본 논문은 PPG센서를 통하여 측정된 생체신호를 학습하여 사용자의 음주량을 추정하는 모델을 제안하였다. 제안된 생체신호를 이용한 음주 측정은 다양한 곳에서 사용될 것으로 기대한다. 예를 들면, 음주운전을 방지하기 위해 자동차 안에 이러한 기능을 추가하여 운전자가 음주한 것으로 판단되면 시동을 아예 걸 수 없도록 한다거나, 건강에 대한 관심이 많아진 최근 애플워치나 갤럭시 워치와 같

이 자주 접할 수 있는데 이러한 웨어러블에 음주 시 건강상태 등을 알 수 있도록 하는 기능을 넣어 사용자의 음주 시 몸 상태에 대해 알 수 있도록 하는 것이다. 향후 이러한 음주량 추정 모델을 빠르게 추정할 수 있는 모델을 연구하고자 한다. 또한 다른 생체신호들과 음주 사이의 관계에 대해 규명하기 위한 실험을 진행할 예정이다.

#### 참고문헌

- [1] 한은규, 박지훈, 조수빈, 최혜정, 강태구, “PPG 센서를 이용한 CNN기반의 음주 상태 추정 기술,” 대한전기학회 학술대회 논문집, 2019.11, 205-206 (2 pages)
- [2] 대학내일20대연구소, SN2018-7, ‘대학생의 1회 음주량은?’, 남민희 에디터, 2018.02.20, <https://www.20slab.org/Archives/25679>
- [3] Ioannis E. Livieris, Emmanuel Pintelas & Panagiotis Pintelas, “A CNN&#8211;LSTM model for gold price time-series forecasting,” Neural Comput Appl. <https://doi.org/10.1007/s00521-020-04867-x>
- [4] Junyong You, Jari Korhonen, “Deep Neural Networks for No-Reference Video Quality Assessment,” IEEE, 22-25 Sept. 2019
- [5] 황철현, 신강욱, “미세먼지 예측 성능 개선을 위한 CNN-LSTM 결합 방법,” 한국정보통신학회논문지, Vol.24.No.1:57-64, 2020

본 과제(결과물)는 교육부와 한국연구재단의 지원으로 지원을 받아 수행된 디지털 신기술 인재양성 혁신공유대학사업의 연구결과입니다.