

<학술논문>

DOI <https://doi.org/10.3795/KSME-B.2021.45.5.261>

ISSN 1226-4881(Print)

2288-5234(Online)

광용적맥파(PPG)의 심층신경망(DNN) 분석을 통한 원격의료 데이터의 신뢰성 평가[§]

김지운^{*†} · 박성민^{**} · 최성욱^{*}

* 강원대학교 기계의용공학과, ** 강원대학교 의학전문대학원

Reliability Assessment of Telemedicine Data by Analyzing Photoplethysmography with Deep Neural Network Technology

Ji Woon Kim^{*†}, Sung Min Park^{**} and Seong Wook Choi^{*}

* Dept. of Mechanical & Biomedical Eng., Kangwon Nat'l Univ.,

** Dept. of Thoracic and Cardiovascular Surgery, School of Medicine, Kangwon Nat'l Univ.

(Received February 4, 2021 ; Revised March 29, 2021 ; Accepted April 1, 2021)

Key Words: Deep Neural Network(심층신경망), Photoplethysmography(광용적맥파), Telemedicine(원격의료), Reliability(신뢰성), Long Term Potential(장기강화)

초록: 광용적맥파(PPG: photoplethysmography)는 측정이 용이하고 심폐기능과 관련된 정보를 제공하므로 원격의료에 자주 사용되지만, 동잡음에 취약하고 질환과 환자의 특징에 따라 다양한 파형이 나타나기 때문에 자동화된 알고리즘을 만들기 어려웠다. 최근, COVID19의 확산으로 원격진료가 활성화됨에 따라 PPG 신호를 자동분석하고 신뢰성이 높은 데이터를 선별하기 위한 심층신경망(DNN) 기술의 적용이 늘어나고 있다. 본 연구에서는 뇌의 LTP(long term potential) 현상을 재현한 DNN을 이용하여 PPG를 분석하고 이를 바탕으로 함께 측정한 SPO2(saturation pulse oxymetry)의 신뢰성을 평가하였다. LTP-DNN은 동잡음이 포함된 58개의 PPG 데이터를 분석하여 정상적으로 측정한 데이터를 선별할 수 있었으며, SPO2의 오류 또한 예측할 수 있었다. 움직이는 상황에서도 기존에 상용화된 SPO2 기기보다 정확한 HR을 제공하였으며 PPG 파형을 표준화함으로써 개인 간의 파형 차이를 비교할 수 있게 하였다.

Abstract: Photoplethysmography (PPG) is often used in telemedicine because it enables convenient measurement and provides data related to cardiopulmonary function. However PPG is difficult to analyze using an automated algorithm because of its vulnerability to motion artefacts and the diversity of the waveforms according to the characteristics of individuals and diseases. Recently, as the use of telemedicine has become more frequent due to the outbreak of COVID19, the application of deep neural network (DNN) technology in the analysis of PPG and selection of reliable data has increased. In this study, PPG was analyzed using DNN techniques to reproduce the long-term potential (LTP) phenomenon in the brain. Moreover, the reliability of measuring saturation pulse oxymetry (SPO2) simultaneously was evaluated using the LTP-DNN. The LTP-DNN was able to evaluate faultless data by inspecting 58 PPG datasets, including 29 fault data, and could determine the possibility of failure in SPO2 measurement as well. Even in a moving situation, the LTP-DNN provides more accurate heart rate (HR) measurements than commercial SPO2 devices do. It can also be used to normalize the PPG waveform to identify waveform differences between individuals.

1. 서 론

최근, 코로나19와 같은 감염병에 대응하기 위해

비대면 원격의료의 확산됨에 따라 ‘원격의료데이터의 신뢰성 향상’과 ‘정상/비정상 데이터 구분’을 위해 인공지능 기술의 적용이 시도되고 있다.^(1~10) 원격의료에는 광용적맥파(PPG: photoplethysmography) 측정이 자주 사용되는데 그 이유는 PPG 센서의 부착이 용이하여 전문 지식이 없는 환자가 쉽게

§ 이 논문은 대한기계학회 2020년 학술대회(2020. 12. 16.-24., 온라인) 발표 논문임.

† Corresponding Author, swchoe@kangwon.ac.kr

© 2021 The Korean Society of Mechanical Engineers

사용할 수 있고 가격이 저렴하기 때문이다.^(11,12) (PPG는 혈관을 통과한 빛의 양을 측정한 것이다. 즉, 수축기혈압과 확장기 혈압에 의해 혈관이 팽창, 수축하기 때문에 혈관을 통과하는 빛의 흡수량 또한 감소, 증가하게 되는데 혈관을 투과한 빛을 측정한 PPG 신호는 침습적 혈압과형과 유사한 형태를 보인다.) PPG는 환자의 질환, 나이, 혈압 등에 따라 파형의 형태가 달라지는 특징이 있고 맥박, SPO2(saturation pulse oxymetry) 등 다양한 생체 정보를 제공하며 휴대가 간편하기 때문에 의료 취약지역에 보급이 용이하다.^(13,14) 이러한 이유로 최근 PPG를 이용하여 질환을 예측하거나 개인의 특징을 인식하기 위한 연구가 진행되고 있다. 그런데 원격의료망을 통해 매일 수집되는 방대한 의료데이터를 분석할 수 있는 자동화기기, 소프트웨어의 신뢰성이 낮기 때문에 사람이 직접 데이터를 분석해야 하는 단점은 원격의료의 임상 적용을 어렵게 하는 주된 원인이었다. 특히, PPG 신호는 동잡음에 영향을 받기 쉬운데 기존의 디지털 신호 처리 기술로는 이러한 잡음을 인지하거나 제거하기 어려웠다.⁽¹⁵⁻¹⁸⁾

최근에는 PPG 등을 통해 측정한 의료데이터의 신뢰성을 높이기 위해 심층신경망(DNN: deep neural network) 기술을 이용하려는 시도가 이어지고 있다. 예를 들어 CNN 또는 LSTM 등의 기술을 이용하여 측정된 PPG 신호가 환자 본인의 것인지를 판단하고, PPG 분석을 통해 측정한 심박수(HR: heart rate)를 다른 장치에서 얻은 심박수와 비교하여 데이터의 신뢰성을 검증하려 한 연구 결과가 발표된 바 있다.⁽¹⁾ 또한, CNN 기술을 통해 측정된 PPG에 생체정보와 무관한 잡음이 포함되어있는지를 판정하고 HR 등을 추정하려는 시도가 있었다.⁽²⁾ HR 측정의 신뢰성을 높이거나 기존의 분석방법으로 진단하기 어려운 질환을 판정하려는 시도 또한 있었다.⁽³⁻⁸⁾

지금까지 발표된 인공지능망 기술이 PPG 신호를 신뢰성 있게 분석할 수 있다는 뚜렷한 사례는 제시되지 않았다.^(1,2,19) 기존 연구를 통해 CNN, LSTM과 같이 많은 뉴런을 가진 심층신경망(DNN)을 훈련하기 위해서는 많은 양의 학습데이터가 필요하다는 것을 알 수 있었다. 반면, 생체데이터를 충분히 확보하는 것이 매우 어렵다는 것을 사례를 통해 알 수 있었다. 그 외에도 많은 기계학습 시간이 소요되었고 많은 연산 시간이

소요되며 고성능 컴퓨터에서만 사용 가능한 단점이 있었다.⁽¹⁹⁾

인공신경망과 달리 사람의 뇌는 적은 학습데이터로도 효과적인 학습이 가능하였는데, 이것은 뇌의 신경망에 입력된 신호가 일정 시간 동안 반복되는 LTP(long term potential) 현상이 그 이유인 것으로 추측되고 있다.^(20,21) 반면, 인공신경망에는 입력데이터의 배열이 한 번에 입력된 후, 결과데이터를 한번 출력하는 차이점이 있다.⁽²¹⁾ 본 연구에서 제안한 신경망은 모든 입력 데이터를 한 번에 입력하지 않고 일부만 입력한 후 일부만 출력을 생성한다.⁽²²⁾ 예를 들어, 2분 가량 PPG 신호를 측정하면 1.2초의 신호만 입력으로 사용하되 입력의 위치를 20 msec씩 변경하여 600번 입력이 반복되도록 하였다. 출력 영역도 입력과 함께 이동한다. 만일 x라는 신호가 입력데이터에 포함되어 있다면 x는 위치를 조금씩 바뀌며 인공심층신경망에 반복하여 입력되는데 이것은 뇌의 LTP 현상을 DNN에서 유사하게 재현한 것이다.⁽²³⁾ 기계학습 측면에서 볼 때, 2분 가량 측정된 한 개의 데이터를 일부분이 중첩되었지만, 600개의 학습데이터를 나누어 기계학습의 효과를 높인 것이다.^(15,24-26)

본 연구의 목적은 제안한 LTP 모사 심층신경망(LTP-DNN)을 PPG 신호의 특징을 인식하고 잡음 영역을 판정하는 알고리즘에 적용하는 것이다. 또한, 완성된 LTP-DNN을 이용하여 HR과 같은 심박동 정보를 측정하고, 심박동 신호와 유사한 동잡음을 구분하였다. 또한, LTP-DNN을 통해 얻은 PPG 신호의 시간대별 특징을 추출한 후 개인 간 차이를 관찰하였다.

2. 본 론

2.1 학습데이터의 구성

본 연구를 진행하기 위해 Physionet에서 BIDMC PPG and respiration dataset(BIDMC)과 MIMIC dataset(mimicdb)을 사용하였으며, ㈜바이오톨스 환자감시장치를 이용하여 자체 측정한 dataset을 사용하였다.^(27,28) 이 데이터를 모두 취합하여 32명의 중환자 데이터와 한 명의 건강한 사람의 데이터를 확보한 뒤, 샘플링 주파수를 통일하기 위해 62.5 Hz로 조정(down-sampling)하였다.

환자 데이터를 32개 사용한 이유는 환자의 질환에 따라 다양한 형태의 파형이 나타났기 때문

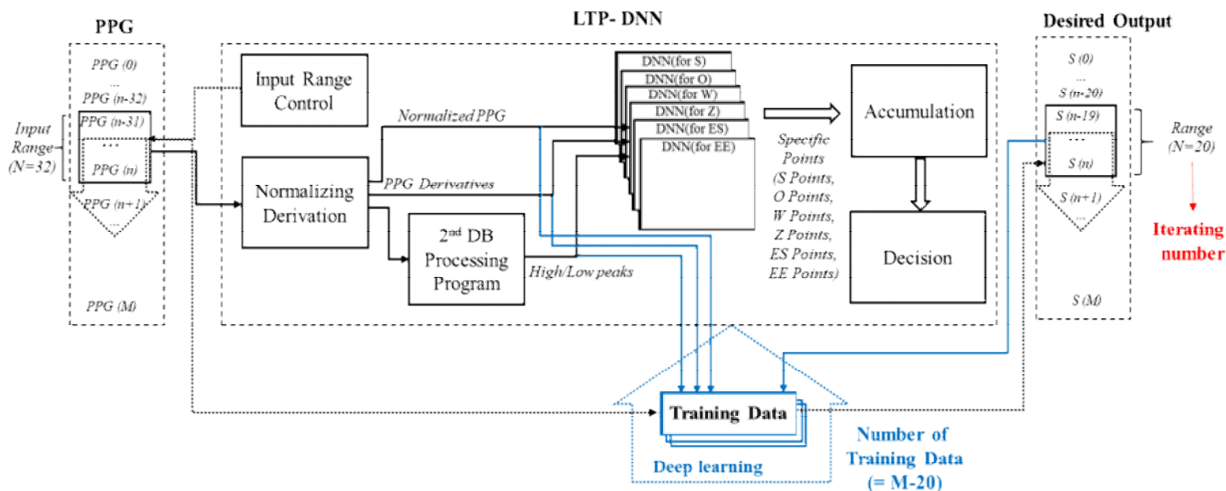


Fig. 1 Structure of LTP DNN

이다. 반면, 정상인의 경우는 PPG 파형이 일정하였기 때문에 한 명의 데이터만 학습데이터로 사용했음에도 다른 정상인의 PPG 파형 분석에서 오류를 일으키지 않았다. 환자 데이터 외에 추가적으로 정상인의 PPG를 측정할 또 다른 이유는 동 잡음 및 기타의 측정 오류에 대한 학습데이터를 확보하기 위한 것이었다. 학습데이터에 사용한 정상인 1인의 데이터는 신경망 평가에 사용되지 않았다. LTP-DNN 평가 중 정상인 데이터는 학습데이터와 관련이 없는 정상인 6명에게서 측정한 데이터를 사용하였다.

2.2 LTP 모사 심층신경망

심층신경망은 뇌의 신경망 구조를 본떠서 입력과 출력을 가진 인공 뉴런을 구성하고 다른 뉴런과 연결된 신경망을 구성한 것이다. 그러나 실제 뇌의 신경망에는 입력된 신호가 여러 번 반복하여 나타나는 현상인 LTP(long term potential) 현상이 나타나는데 인공심층신경망은 이를 재현하지 못하였다.^(20,21)

Fig. 1은 인공신경망에 입력된 신호가 일정 시간 동안 반복해서 신경망에 다시 입력되게 하는 LTP 현상을 재현한 알고리즘 구조를 나타낸 것이다. 알고리즘은 PPG 신호의 일부분을 잘라서 심층신경망에 입력한 후 심층신경망이 찾는 특징점이 포함된 데이터의 위치에 표시를 남긴다. 심층신경망은 20개의 데이터 영역 중 한 곳에 표시를 남길 수 있으며 입력신호가 변경될 경우, 표시할 수 있는 데이터의 영역도 동시에 변경된다. 즉, PPG 데이터 중에서 심층신경망의 입력데이터의

위치가 바뀔에 따라 LTP-DNN이 PPG 데이터에 표시할 수 있는 위치가 바뀌게 되는데 입력과 출력의 범위가 한 개씩 바뀔에 따라 PPG 데이터에는 0개에서 20개까지 중복하여 표시할 수 있다. 예를 들어 PPG 데이터 중 한 곳에 찾고자 하는 어떤 S점이 있을 경우, 입력 데이터는 1.2초 동안 반복적으로 심층신경망에 입력되고 S점이 포함된 PPG 데이터에는 심층신경망이 최대 20회까지 누적된 판정 표시를 남기게 된다. DNN은 S점을 판정할 때, 각각의 위치가 S점인지 아닌지를 참, 거짓으로 출력하지만, LTP-DNN은 S점의 위치를 0~20까지의 숫자로 표시한다. LTP-DNN이 10보다 크다면 DNN이 기계학습에서 사용한 학습데이터의 S와 동일한 형태로 판정했음을 의미한다. LTP-DNN이 10보다 작다면 PPG 파형에 DNN에 혼란을 줄 수 있는 신호가 존재하더라도 기계학습에서 사용한 학습데이터의 S와 동일하지 않은 것으로 판단했다고 볼 수 있다.

Fig. 2와 같이 6개의 LTP-DNN은 파형의 특징을 인식한 후 심장의 수축과 관련된 파형 S점(systolic point), 심장의 수축 전 발생하는 O점(onset point), 박동 펄스에 의한 1차 미분 파형 W점, 반사파에 의한 파형 Z점(1차 미분 파형에서 반사파로 인해 발생한 첫 번째 peak) 및 에러 영역의 시작(ES)과 끝(EE)이 시작되는 지점을 표시한다.⁽²⁵⁾ 신경망의 입력에서 찾은 각각의 특징점을 표시하는 구간을 판정 구간이라고 하며 판정 구간은 20개로 설정하였다. PPG는 62.5 Hz로 sampling되며, 1.2 sec 영역 내에 측정된 PPG 데이터 중 32개를 심층신경망의 입력으로 사용한다. PPG의 파형 인식의 효




Fig. 2 Singular points determined by the LTP-DNN

울성을 높이기 위해 판정 구간의 측정값 20개는 모두 사용하고, 판정 구간과 떨어진 측정값은 16개만 사용하였다. PPG의 미분을 구한 후 동일한 방법으로 선별한 32개의 데이터를 심층신경망의 입력에 포함시켰다. 또한, PPG 파형의 high/low peak 점과 1차 미분 파형의 high peak 값을 각각 20개씩 표시한 값도 신경망의 입력에 포함하였다. 각 심층신경망의 입력은 총 124개로 구성되어 있으며 124개씩의 신경을 가진 두 개의 은닉층과 21개의 출력층 한 개로 구성되어 있다. 출력층 중 21번째 출력은 판정 구간 내에 찾고자 하는 특징점이 없음을 의미하므로 PPG 데이터에 표시되지 않는다.

특이점을 판정하는 심층신경망 필터의 훈련을 위해 32명의 중환자 데이터와 한 명의 정상인 데이터가 학습데이터로 사용되었으며, adam_optimizer와 deep learning 기술을 사용하여 기계학습을 수행하였다. 훈련데이터에 대한 정확도는 1,000 epoch 일 때에 O, S, W, Z, ES, EE 각각 93.4%, 97.5%, 95.2%, 96.5%, 98.9%, 98.2%였다.

2.3 생체데이터의 수집 및 신뢰성 평가 방법

생체데이터는 강원대학교 병원의 임상실험(임상시험위원회의 승인번호 A-2019-11-007-007)을 통해 확보하였다. 6명의 실험참가자는 24~36세 정상인이며 총 10회간 30초 이상 SPO2(PPG) 데이터를 측정하였다. Fig. 3과 같이 5회의 측정은 정상적인 상태에서 측정하였으나 5회의 측정은 센서가 부착된 손가락을 20°~30° 범위에서 분당 100회의 주기로 내전(flexion), 외전(extension)을 반복하며 측정하였다. 정상 측정을 1회한 후 곧바로 비정상 측정을 실시하였으므로 정상 측정과 비정상 측정간에 환자의 심박동이 달라지는 등의 생리적 변



Fig. 3 SPO2, HR measurement with a SPO2 monitor

화는 관찰되지 않았다.

원격의료장비는 실험참가자에게서 측정된 PPG 파형과 SPO2 값, SPO2 측정기기(BPM-190, Bionics, Inc., Korea)가 측정된 HR을 서버로 전송하였으며, 본 연구에서 제안한 LTP-DNN 적용 프로그램을 이용하여 PPG의 파형을 분석하여 특징점(S점, O점, W점, Z점, ES, EE)을 판정하였다. LTP-DNN에 의한 W점을 기반으로 HR을 계산하였으며 이를 정상, 비정상 상태에서 SPO2 기기가 측정된 HR과 비교하였다.

LTP-DNN은 모든 특징점 판정을 20회까지 중복하여 판정하였다. 심박동 시 발생하는 S, O, W점의 판정횟수의 최대 합은 60이다.

LTP-DNN이 심박동을 인식한 정도를 정량적으로 나타내기 위해 S, O, W점의 판정횟수의 합을 점수화하였다. 또한, 비정상적인 잡음이 검출되지 않았을 때 즉, ES, EE가 심박동 범위 내에 없는 경우는 40점으로 하여 심박동 인식 정도의 점수에 합산하고 존재하는 경우는 최하 0점을 합산한다. 본 연구에서는 심박동을 인식하는 점수를 인식도(RS: recognition score)로 표시하였다. 따라서 심박동 인식도는 최하 0점에서 최대 100점까지 나타낼 수 있다. 심박동 인식도(RS)를 이용하여 정상 측정 데이터와 비정상 측정 데이터 사이에 심박동 인식도의 차이를 비교하였다. Z점은 환자와 질환의 특징을 나타낸 것으로 일부 환자에게는 보이지 않는 경우가 있으므로 RS의 계산에는 제외하였다.

마지막으로 SPO2기기에서 측정된 정상 SPO2 값과 비정상 SPO2 값의 차이를 분석하였다. 모든 심박수에서 RS>80인 심박수의 비율이 90% 이상인 경우를 정상의 판정의 조건으로 정했을 때, 비정상적인 SPO2 값을 판정한 비율을 계산하였다.

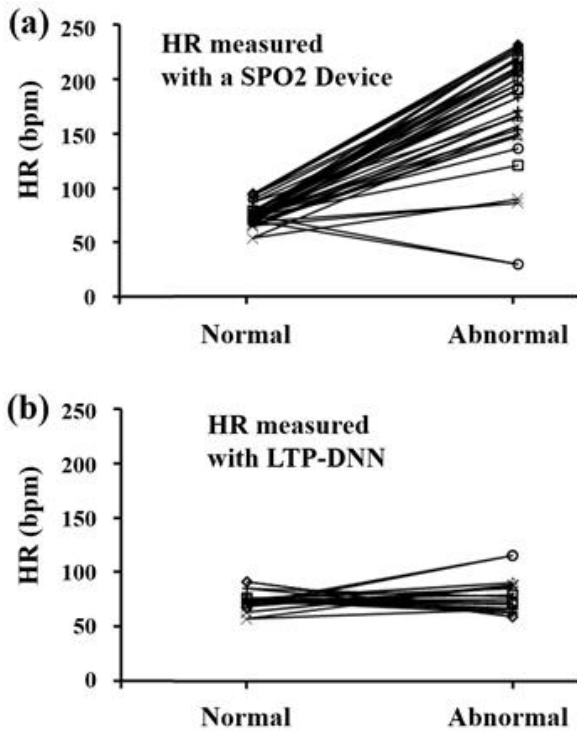


Fig. 4 HR differences between normally and abnormally measured with (a) a SPO2 device (BPM-190, Bionics, Inc., Korea); (b) LTP-DNN




Fig. 5 Recognition scores (RS) of heart beats obtained with LTP-DNN in normal and abnormal experiments

2.4 생체데이터의 신뢰성 평가 결과

Fig. 4(a)는 정상, 비정상 상태에서 SPO2 기기 의해 측정된 HR 값이 크게 변동하였음을 보여준다. 이에 비해 Fig. 4(b)는 동일한 장치로 동시에 측정된 PPG를 LTP-DNN을 이용하여 HR을 측정하였음에도, HR의 변화가 크게 나타나지 않았다. 참고로 LTP-DNN 알고리즘은 비정상 심박동에 대해 HR을 계산하지 않도록 설계되었으나 비정상 심박동 중 일부 정상적으로 인지한 심박동 정보(W point)를 이용하여 대략적인 HR의 추정이 가능하였다.




Fig. 6 SPO2 measured with a SPO2 monitor in normal and abnormal experiments

Fig. 5와 같이 LTP-DNN을 이용하여 정상 상태의 PPG를 분석하였을 때, 모든 심장박동에 대한 인식도(RS)가 평균 98.4(최소 90.3)였지만, 비정상 상태의 PPG를 분석하였을 때 RS의 평균은 48.4(최대 78.8)로 낮았다. 따라서 LTP-DNN의 RS 값이 80 이상인 경우를 정상 측정으로 하였을 때, 정상 측정과 비정상 측정을 완벽히 구분할 수 있었다.

Fig. 6과 같이 비정상 상태의 SPO2 측정값은 정상 상태의 SPO2에 비해 낮게 측정됨을 확인할 수 있었다. 정상인의 SPO2 평균은 $98.1 \pm 0.9\%$ 였으나 동일한 실험참가자에 대해 비정상 상태에서 측정된 값은 $79.7 \pm 16.5\%$ 로 $-18.4 \pm 16.7\%$ 의 오차가 발생하였다. SPO2 값이 80% 이하인 값은 심각한 호흡 장애가 있다고 판정할 수 있는 값이기 때문에 신체적으로 정상적인 상태의 피실험자에 대해 중대한 측정 오차가 발생함을 확인할 수 있었다.

2.5 PPG 파형의 개인차 분석

본 연구에서는 총 13명(재택 환자 7명과 정상인 자원자 6명)의 PPG 파형에서 개인 간의 특징을 관찰할 수 있는지 확인하기 위해 PPG의 미분파형의 구간별 특징을 비교, 분석하였다. 잡음의 영향을 제거하기 위해 RS 값을 이용하여 신뢰성 있는 파형을 선별하였고, PPG 측정 중 base line이 움직이면서 발생하는 차이를 제거하기 위해 PPG의 미분값을 이용하였다. LTP-DNN을 통해 정상적($RS \geq 80$)으로 측정한 W-W 구간의 미분파형을 10분할하고 각 구간의 평균값($D_0 \sim D_9$)을 구하였다. 30개의 정상적인 PPG 파형으로부터 30개의 구간 평균($D_{0,0} \sim D_{9,30}$)을 다시 구하고 각 구간의 평균값과 표준 편차를 통해 신뢰구간 95%의 구간으로 구간의 기준값과 허용 범위를 설정하였다. 기준값과 허용 범위를 결정할 때, 기존에 측정된 30회의 데이터




Fig. 7 AUC curve of the personnel identification with PPG waveform

를 이용하여 각 구간의 평균값과 표준편차를 이용하였으며 정상적인 측정값이 존재할 확률이 통계적으로 95%를 달성할 수 있도록 허용 범위를 설정하였다. Fig. 7과 같이 새로운 측정값에서 각 10개의 구간 중 기준 구간 내에 존재하는 값이 몇 개인지를 통해 개인 간의 차이를 판단할 수 있었으며 판정의 정확성을 AUC curve로 나타내었다. 예를 들어 10구간이 모두 기준 범위에 들어와야 동일인으로 인정한 경우에 동일인임에도 감지되지 않았으며, 2구간까지 허용할 경우 동일인임을 감지할 가능성 즉, 동일인에 대한 sensitivity가 75%까지 상승하였으나 타인임에도 동일인으로 잘못 판단하는 확률, FPR은 25%로 상승하였다.

3. 토 의

본 연구에서는 의료기기의 사용 경험이 없는 일반인이 스스로 측정하여 전송한 의료데이터에 대해 동잡음에 의한 오류를 감지하고 사용자에게 재측정을 요구할 것인지를 결정하게 하는 심층신경망 알고리즘의 정확성을 판정하였다. 실험에 참여한 7명의 환자는 10분 이상 SPO2 기기의 사용 교육을 수행한 후, 자택에 설치된 장치를 사용하여 총 35회 생체 데이터를 측정하여 서버로 전송하였다. 환자에서 전송된 35건의 의료데이터에서 LTP-DNN을 이용한 심박동 인식도(RS)는 98.9 ± 1.0 점으로 매우 양호한 것으로 판정되었으며 의료진이 직접 데이터를 검토한 경우에도 측정 오류와 관련된 징후를 발견할 수 없었다.

비정상적인 측정에 대한 판정을 위해 추가적인 실험이 요구되었으므로 6명의 정상인 임상실험 지원자를 추가 모집하여 정상적인 SPO2의 측정

및 의도적으로 센서가 부착된 손가락을 20~30도 사이에서 움직이게 함으로써 비정상 측정 상황을 재현하였다. 동잡음의 주파수는 분당 90~110회였으며 정상인에게서 측정된 심박동 주파수(분당 54~101회)와 유사하여 기존의 디지털 필터 기술이나 신호처리기술로 구분하기 어려웠다. 비정상조건에서 SPO2 측정 장치를 이용하여 측정한 HR은 직전의 정상조건에서 측정한 HR에 비해 27~193% 높게 측정되었는데 그 이유는 기존의 SPO2 측정 기기가 동잡음에 의한 파형의 변화를 심박동에 포함하였기 때문이다.

이에 비해 LTP-DNN은 동잡음을 비정상 박동으로 인식하여 HR 계산에 포함하지 않았다. 그런데 Fig. 5와 같이 정상적인 심장박동의 인식도(RS) 또한 낮았기 때문에 대부분의 심박동에 대해 HR을 계산하지 않았다. 29회의 비정상 측정 중 7회에 대해서는 HR을 계산하지 않았으며 22회의 비정상 측정 중에는 1~11회의 심장박동을 검출한 후 대략적인 HR을 구하였다. 직전에 정상조건에서 측정한 HR과의 차이는 -9~19% 발생하였으나 SPO2 측정기기에 비해 오차의 범위가 좁았다. 무엇보다도 측정된 결과가 비정상임을 구분할 수 있는 RS 값을 제공하기 때문에 측정의 신뢰성을 크게 향상할 수 있었으나 기존의 SPO2 측정기기는 신뢰성을 판단할 수 있는 다른 지표가 제공되지 않았다.

동잡음은 HR뿐만 아니라 펄스산소포화도(SPO2)의 측정값에서 -2~74%까지 큰 폭의 오차를 유발하였다. 평균적으로 -18%의 오차를 유발하였는데 SPO2의 값이 85% 이하인 경우 심각한 호흡 장애로 판정될 수 있기 때문에 동잡음 요인을 판정할 수 없는 기존의 SPO2 측정기기를 이용할 경우, 환자의 상태에 대한 판정이 어려울 것으로 예상된다.^(29,30) 동일환자군에 대해 LTP-DNN이 정상 측정으로 판정한 SPO2에 대해서는 $98.1 \pm 0.9\%$ 로 안정적인 측정이 이루어졌다. 병원 외부에서 측정된 49건(7명)의 SPO2 값은 RS 값을 통해 모두 양호하게 측정된 것을 확인할 수 있었으며 SPO2 값이 $96.4 \pm 0.9\%$ 로 안정적이었다.

참고로 정상조건에서 LTP-DNN은 대부분의 심박동을 검출하였으나 알고리즘의 과도기적 특성에 의해 초기에 측정된 데이터에서 한 개의 심박동을 놓치기 때문에 30초의 PPG 데이터 중 97% 이상 심박동을 검출할 수 있었다. 정상조건에서

측정한 LTP-DNN의 HR은 SPO2 측정기기의 HR과 $-0.65 \pm 2.91\%$ 의 근소한 차이가 관찰되었다. 7명의 자택환자에게서 측정한 49건의 HR은 LTP-DNN으로 측정한 HR과 0.7 ± 1.0 bpm의 비교적 일치하는 값이 관찰되었다. LTP-DNN의 HR과 SPO2 측정기기의 HR의 정확도 및 신뢰성을 비교 평가하기 위해서는 ECG를 이용한 추가적 측정이 필요한 것으로 보이며 향후 추가적인 연구를 통해 규명될 것이다.

마지막으로 Fig. 7에서 총 13명의 PPG 파형을 통해 개인 식별이 가능한지를 나타낸 AUC curve는 개인 간의 차이가 분명히 존재하지만 이를 이용하여 특정인을 식별할 때, 에러의 확률이 매우 높음을 보여준다. 동일인임에도 PPG 파형의 10개 구간 중 2구간 이상 오차가 발생하는 경우가 25% 이상의 확률로 관찰되었는데 이것은 환자에게 뚜렷한 신체적 특징이 나타나지 않았음에도 PPG 파형에 변화가 나타날 수 있음을 보여준다. 또한, 13명 중 8개 구간 이상이 일치하여 서로를 구분하지 못하는 경우도 25% 이상 관찰되었다. PPG 파형을 이용한 개인 인식 기술이 가능할 것으로 예상된 바 있는데 실제 PPG 파형을 이용한 개인 인식이 실현되지 않은 이유는 PPG 파형의 잡음에 의한 것으로 여겨졌다. 그런데 본 연구는 LTP-DNN을 이용하여 비교적 신뢰성 높은 PPG 파형을 추출할 수 있었으나 적은 수의 인원과 데이터를 이용하였음에도 각 개인의 PPG에 변화가 나타났고 서로 다른 타인 간에 일치된 파형이 관찰될 수 있음을 보여주었다.

4. 결 론

본 연구는 SPO2 기기의 사용방법을 숙지한 환자들이 직접 측정한 원격의료 데이터의 신뢰성에 영향을 줄 수 있는 문제점을 입증하지 못하였다. 다만, 정상인 자원자를 대상으로 일정한 동잡음을 유발함으로써 SPO2 기기를 통해 측정한 HR, SPO2 값에 큰 폭의 오류가 발생함을 제시할 수 있었다. 제시된 실험 결과와 같이 기존의 SPO2 기기만으로는 심각한 HR의 오차와 위험한 SPO2의 감소를 구분할 수 있는 방법을 제공할 수 없었다. 본 연구에서 제안한 LTP-DNN은 SPO2 측정과 동시에 측정되는 PPG 파형에서 심장박동의 특성을 정확히 인식하여 비정상 측정을 구분할 수 있었으며, 비정상 측정 상황에서 SPO2 기기에 비해 정확한

HR 값을 제공할 수 있었다. 특히, LTP-DNN에 의해 SPO2를 재측정하도록 판정할 경우, 원격의료 데이터의 신뢰성을 향상할 수 있을 것으로 기대된다.

후 기

본 연구는 한국연구재단 기본연구 과제의 지원을 받아 수행하였으며(No.2020R1F1A107347812), 중소벤처기업부의 기술개발사업의 지원으로 수행되었음(P0011346).

참고문헌 (References)

- (1) Biswas, D., Everson, L., Liu, M., Panwar, M., Verhoef, B. E., Patki, S. and Van Helleputte, N., 2019, "CorNET: Deep Learning Framework for PPG-based Heart Rate Estimation and Biometric Identification in Ambulant Environment," *IEEE Transactions*, Vol. 13, No. 2, pp. 282~291.
- (2) Reiss, A., Indlekofer, I., Schmidt, P. and Van Laerhoven, K., 2019, "Deep PPG: Large-Scale Heart Rate Estimation with Convolutional Neural Networks," *Sensors*, Vol. 19, No. 14, Article 3079.
- (3) Şentürk, Ü., Yücedağ, I. and Polat, K., 2018, "Repetitive Neural Network (RNN) based Blood Pressure Estimation Using PPG and ECG Signals," *Proc. of the 2018 2nd International Symposium on Multidisciplinary Studies and Innovative Technologies (ISMSIT)*, Ankara, Turkey, pp. 1~4.
- (4) Reiss, A., Schmidt, P., Indlekofer, I. and Van Laerhoven, K., 2018, "PPG-based Heart Rate Estimation with Time-Frequency Spectra: A Deep Learning Approach," *Proc. of the 2018 ACM International Joint Conference and 2018 International Symposium on Pervasive and Ubiquitous Computing and Wearable Computers*, New York, USA, pp. 1283~1292.
- (5) Jindal, V., Birjandtalab, J., Pouyan, M. B. and Nourani, M., 2016, "An Adaptive Deep Learning Approach for PPG-based Identification," *Proc. of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pp.

- 6401~6404.
- (6) Everson, L., Biswas, D., Panwar, M., Rodopoulos, D., Acharyya, A., Kim, C. H. and Van Helleputte, N., 2018, "Biometricnet: Deep Learning based Biometric Identification Using Wrist-worn PPG," *Proc. of the 2018 IEEE International Symposium on Circuits and Systems (ISCAS)*, Florence, Italy, pp. 1~5.
 - (7) Lee, M. S., Lee, Y. K., Pae, D. S., Lim, M. T., Kim, D. W. and Kang, T. K., 2019, "Fast Emotion Recognition based on Single Pulse PPG Signal with Convolutional Neural Network," *Applied Sciences*, Vol. 9, No. 16, Article 3355.
 - (8) Yang, Y. L., Seok, H. S., Noh, G. J., Choi, B. M. and Shin, H., 2019, "Postoperative Pain Assessment Indices based on Photoplethysmography Waveform Analysis," *Frontiers in Physiology*, Vol. 9, Article 1199.
 - (9) Zhou, K., Wang, W., Wu, C. and Hu, T., 2020, "Practical Evaluation of Encrypted Traffic Classification based on a Combined Method of Entropy Estimation and Neural Networks," *ETRI Journal*, Vol. 42, No. 3, pp. 311~323.
 - (10) Khan, W., Daud, A., Alotaibi, F., Aljohani, N. and Arafat, S., 2020, "Deep Recurrent Neural Networks with Word Embeddings for Urdu Named Entity Recognition," *ETRI Journal*, Vol. 42, No. 1, pp. 90~100.
 - (11) Lu, G., Yang, F., Taylor, J. A. and Stein, J. F., 2009, "A Comparison of Photoplethysmography and ECG Recording to Analyse Heart Rate Variability in Healthy Subjects," *Journal of Medical Engineering & Technology*, Vol. 33, No. 8, pp. 634~641.
 - (12) Nitzan, M., Babchenko, A. and Khanokh, B., 1999, "Very Low Frequency Variability in Arterial Blood Pressure and Blood Volume Pulse," *Medical & Biological Engineering & Computing*, Vol. 37, No. 1, pp. 54~58.
 - (13) London, G. M. and Guerin, A. P., 1999, "Influence of Arterial Pulse and Reflected Waves on Blood Pressure and Cardiac Function," *American Heart Journal*, Vol. 138, No. 3, pp. 220~224.
 - (14) Zhang, Q., Zeng, X., Hu, W. and Zhou, D., 2017, "A Machine Learning Empowered System for Long-term Motion-Tolerant Wearable Monitoring of Blood Pressure and Heart Rate with Ear-ECG/PPG," *IEEE Access*, Vol. 5, pp. 10547~10561.
 - (15) Blanc, V. F., Haig, M., Troli, M. and Sauvé, B., 1993, "Computerized Photoplethysmography of the Finger," *Canadian Journal of Anaesthesia*, Vol. 40, No. 3, pp. 271~278.
 - (16) Takazawa, K., Tanaka, N., Fujita, M., Matsuoka, O., Saiki, T., Aikawa, M. and Ibukiyama, C., 1998, "Assessment of Vasoactive Agents and Vascular Aging by the Second Derivative of Photoplethysmogram Waveform," *Hypertension*, Vol. 32, No. 2, pp. 365~370.
 - (17) Reuss, J. L. and Bahr, D. E., 2002, "Period Domain Analysis in Fetal Pulse Oximetry," *Proc. of the Second Joint 24th Annual Conference and the Annual Fall Meeting of the Biomedical Engineering Society*, Houston, USA, Vol. 2, pp. 1742~1743.
 - (18) Shelley, K. H., 2007, "Photoplethysmography: Beyond the Calculation of Arterial Oxygen Saturation and Heart Rate," *Anesthesia & Analgesia*, Vol. 105, No. 6, pp. 31~36.
 - (19) Rocha, L. G., Liu, M., Biswas, D., Verhoef, B. E., Bampi, S., Kim, C. H. and Van Helleputte, N., 2019, "Real-time HR Estimation from Wrist PPG Using Binary LSTMs," *Proc. of the 2019 IEEE Biomedical Circuits and Systems Conference (BioCAS)*, Nara, Japan, pp. 1~4.
 - (20) Lake, B. M., Ullman, T. D., Tenenbaum, J. B. and Gershman, S. J., 2017, "Building Machines that Learn and Think like People," *Behavioral and Brain Sciences*, Vol. 40, Article 253.
 - (21) Cooke, S. F. and Bliss, T. V. P., 2006, "Plasticity in the Human Central Nervous System," *Brain*, Vol. 129, No. 7, pp. 1659~1673.
 - (22) Kim, J., Park, S. and Choi, S., 2020, "Automatic Parameter Acquisition of 12 Leads ECG Using Continuous Data Processing Deep Neural Network," *Journal of Biomedical Engineering Research*, Vol. 41, No. 2, pp. 107~119.
 - (23) Karimian, N., Guo, Z., Tehranipoor, M. and Forte, D., 2017, "Human Recognition from Photoplethysmography (PPG) based on Nonfiducial

- Features,” *Proc. of the 2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, New Orleans, USA, pp. 4636~4640.
- (24) Elgendi, M., 2012, “On the Analysis of Fingertip Photoplethysmogram Signals,” *Current Cardiology Reviews*, Vol. 8, No. 1, pp. 14~25.
- (25) Elgendi, M., Liang, Y. and Ward, R., 2018, “Toward Generating More Diagnostic Features from Photoplethysmogram Waveforms,” *Diseases*, Vol. 6, No. 1, Article 20.
- (26) Gonzalez, R., Manzo, A., Delgado, J., Padilla, J. M., Trénor, B. and Saiz, J., 2008, “A Computer based Photoplethysmographic Vascular Analyzer through Derivatives,” *Proc. of the 2008 Computers in Cardiology*, Bologna, Italy, pp. 177~180.
- (27) Goldberger, A. L., Amaral, L. A., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G. and Stanley, H. E., 2000, “PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals,” *Circulation*, Vol. 101, No. 23, pp. 215~220.
- (28) Pimentel, M. A., Johnson, A. E., Charlton, P. H., Birrenkott, D., Watkinson, P. J., Tarassenko, L. and Clifton, D. A., 2016, “Toward a Robust Estimation of Respiratory Rate from Pulse Oximeters,” *IEEE Transactions on Biomedical Engineering*, Vol. 64, No. 8, pp. 1914~1923.
- (29) Kim, J., Park, S. and Choi, S., 2021, “Reliability of the Photoplethysmographic Analysis Using Deep Neural Network (DNN) Algorithm,” *Journal of Biomedical Engineering Research*, Vol. 42, No. 2, pp. 31~38.
- (30) Kim, J., Park, S. and Choi, S., 2021, “Real-time Photoplethysmographic Heart Rate Measurement Using Deep Neural Network Filters,” *ETRI Journal* (in press).